Local Knowledge AI

요구사항 정의서 | 要件定義書 | v1.0

항목	내용
문서 상태	검토용 초안 (정책 4개 확정, 세부 수치 추후 확정)
기준일	2026-10-19
프로젝트	Local Knowledge AI
개발 환경	MacBook Pro M1 / RAM 8GB / VS Code
목적	Ollama · RAG · AI Harness 학습 및 실제 활용 가능한 로컬 문서 검색 서비스

1. 개요 및 목적

사용자가 PDF/TXT 문서를 업로드하면, 시스템이 문서를 추출·분할·임베딩하여 검색 가능하게 저장하고, 질문 시 관련 문서를 찾아 Ollama 기반 LLM이 근거 중심으로 답변하는 로컬 웹 애플리케이션을 개발한다.

- 기술 학습: 로컬 LLM, 임베딩, 벡터 검색, RAG 파이프라인과 AI Harness 이해
- 실용성: 개인 지식 검색을 구현하고 향후 사내 지식 검색으로 확장 가능한 구조 확보
- 실무 학습: 요구사항 정의 → 기본설계 → 상세설계 → 구현 → 테스트 → GitHub 형상 관리

2. 확정된 기본 정책

분야	확정 정책	설계 영향
사용자	1인 개인 사용자	MVP 로그인/권한 및 users 테이블 제외
지원 문서	PDF 및 TXT	텍스트 기반 PDF와 UTF-8 TXT 우선
답변 범위	업로드 문서 근거만	외부 검색 제외, 근거 부족 시 답변 보류
실행 환경	개인 Mac 로컬 실행	localhost 바인딩, 소형 모델 및 단일 요청 중심

3. 시스템 구성 및 기술 스택 (잠정)

계층	기술	설명
Frontend	React 19.x / TypeScript / Vite	채팅 UI, 업로드 UI, 처리 상태 및 근거 표시
Backend	Java 21 / Spring Boot 3.5.x	REST API 및 기능별 서비스 구성

계층	기술	설명
AI 연동	Spring AI 1.1.x / Ollama	검색 및 생성 모델 어댑터
DB	PostgreSQL + pgvector	메타데이터와 임베딩 저장
관리	Maven / Flyway / GitHub	빌드, 스키마 변경, 형상 관리

정확한 패치 버전, 모델 및 임베딩 차원은 설치/호환성 검증 후 확정한다. 최초에는 하나의 Spring Boot 애플리케이션을 기능별 모듈로 분리하는 Modular Monolith 방식을 적용한다.

4. MVP 기능 요구사항

ID	우선	기능	요구 내용
FR-001	P0	파일 업로드	PDF/TXT 허용, 확장자 및 파일 특성 확인, 크기 제한, 실패 안내
FR-002	P0	텍스트 추출	텍스트 PDF 및 UTF-8 TXT 추출, 이미지 전용 PDF는 지원 범위 안내
FR-003	P0	청크/임베딩	텍스트 분할, 각 청크의 문서 ID 및 가능한 페이지 정보 보존, 벡터 저장
FR-004	P0	문서 검색	질문에 관련된 청크 조회, 청크 ID/문서 ID/검색 기준 전달
FR-005	P0	LLM 답변	Ollama 호출 및 검색 문서 기반 답변 생성, 호출 오류 처리
FR-006	P0	근거 부족 보류	검색 결과가 없거나 불충분할 때 근거 부족 안내, 추측 억제
FR-007	P0	근거 표시	실제로 검색된 문서의 파일명·청크·가능한 페이지 정보 표시
FR-008	P0	기본 채팅 UI	질문 입력, 진행 상태, 답변, 출처, 오류 상태 표현
FR-009	P0	문서 처리 상태	UPLOADED/PROCESSING/READY/FAILED 관리 및 실패 원인 표시
FR-010	P1	문서 관리	업로드 목록, 삭제, 청크/벡터 삭제 정책
FR-011	P1	대화 기록	세션 및 질문·답변 영구 저장
FR-012	P1	스트리밍	SSE 기반 점진적 답변 표시
FR-013	P2	고급 검색	Hybrid Search 및 Reranking
FR-014	P2	Harness 확장	프롬프트 버전, 검증, 평가, 실행 기록

5. 사용자 시나리오 및 데이터 흐름

UC-001 문서 등록

1) 파일 선택 → 2) 형식/크기 검증 → 3) 원본 저장 → 4) 텍스트 추출 → 5) 청크 분할 → 6) 임베딩 생성 → 7) 메타데이터 및 벡터 저장 → 8) READY/FAILED 상태 표시

UC-002 문서 질의응답

1) 질문 입력 → 2) 질문 벡터화 → 3) 관련 청크 검색 → 4) 근거 충분성 판단 → 5) Ollama 답변 생성 → 6) 실제 검색 출처 연결 → 7) 화면 표시

UC-003 근거 부족

자료가 없거나 답을 뒷받침하지 못하는 경우 답변 생성을 보류하고 “업로드된 문서에서 질문에 대한 충분한 근거를 확인할 수 없습니다.”를 안내한다.

6. 비기능 요구사항

ID	항목	요구 내용
NFR-001	로컬 운영	모델 설치 후 핵심 흐름 오프라인 가능; 개발 서버 localhost 우선
NFR-002	자원	M1 8GB에서 구동 시험; 소형 양자화 LLM; 동시 추론 제한
NFR-003	안정성	Ollama 실패/타임아웃 처리, 무제한 재시도 금지
NFR-004	근거 품질	근거 부족 시 보류, 실제 검색 출처만 연결, 평가 질문 세트 마련
NFR-005	보안	파일 크기·형식 검증, 경로 순회 방지, 민감 로그 배제
NFR-006	유지보수	DTO/Entity 분리, 기능별 모듈, 설정 외부화
NFR-007	테스트	단위·통합 테스트, 정상/실패/경계 조건 검증
NFR-008	문서화	GitHub 문서·ADR·PROJECT_STATUS.md·Flyway 사용

7. 데이터 요구사항 및 저장 원칙

- documents: 원본 파일 경로, 파일명, 유형, 처리 상태, 생성 시간 및 오류 메타데이터
- document_chunks: 문서 FK, 청크 순번, 추출 내용, 벡터, 페이지 메타데이터
- 추후 P1: chat_sessions, chat_messages, message_sources (근거 이력 보관)
- 관계: Document 1:N DocumentChunk; 답변 근거는 실제 Chunk ID와 연결
- 파일 저장: 원본은 로컬 저장소; DB에는 경로·메타데이터·청크·벡터 보관

중복 파일, 삭제/재처리, 업로드 최대 크기, 백업/복원, 임베딩 모델 교체 시 재인덱싱 정책은 후속 설계의 결정 사항이다.

8. 답변 근거 및 신뢰성 정책

- 검색된 자료는 데이터로 취급하며 문서 속 명령을 시스템 지시로 실행하지 않는다.
- 검색 유사도만으로 정답을 보증하지 않는다. 검색 결과가 있어도 근거 불충분 가능성을 고려한다.
- 출처 파일명이나 페이지를 LLM이 임의 생성하지 않도록, 애플리케이션이 실제 검색 메타데이터로 출처를 조립한다.
- 모든 환각이 사라진다고 주장하지 않으며, 정답 존재/부재/유사 질문/문서 충돌/프롬프트 인젝션을 평가한다.

9. MVP 인수 조건 (受入　件)

ID	검증 기준
AC-01	정상 텍스트 PDF 및 UTF-8 TXT를 업로드·처리할 수 있다.
AC-02	잘못된 파일/손상 PDF/텍스트 없는 PDF를 안전하게 거부하거나 실패 표시한다.
AC-03	유효한 청크가 원본 문서와 연결되어 pgvector에 저장된다.
AC-04	문서 안에 명시된 내용으로 질문하면 실제 검색 근거와 함께 답변한다.
AC-05	문서 외 질문이나 불충분한 근거 질문은 정해진 문구로 보류한다.
AC-06	출처가 실재하는 문서/청크를 가리킨다.
AC-07	LLM 및 문서 처리 오류를 사용자에게 구분하여 표시한다.
AC-08	M1 8GB 로컬 환경에서 주요 흐름 실행 및 테스트가 확인된다.
AC-09	테스트 결과 및 로컬 실행 절차를 GitHub 문서에서 재현할 수 있다.

MVP 완료 판정: 모든 P0 요구사항을 구현하고 해당 인수 조건의 정상·실패 사례를 테스트한 상태. 현재는 구현·테스트 전이며 통과로 표시하지 않는다.

10. 범위 외 및 위험

초기 범위 외: 로그인·다중 사용자·클라우드 배포·웹검색·OCR·DOCX/Excel/PowerPoint·에이전트의 외부 시스템 실행. 이후 요구사항 변경 절차를 거쳐 추가한다.

위험	대응
메모리 부족/느린 추론	소형 모델, 컨텍스트 제한, 동시 요청 제한, 실측
검색 실패/잘못된 답	Chunking 평가, 근거 부족 처리, 출처 및 답변 검증
PDF 추출 불가	이미지 PDF 지원 제외 안내 및 오류 상태 관리
의존성 불일치	공식 호환성 확인 후 버전 고정
문서/개인정보 유출	로컬 접근 제한, 로그 관리, 공개 저장소에서 실데이터 제외

11. 미결정 항목 및 다음 단계

- 업로드 최대 용량 및 파일 개수 제한
- 추론/임베딩 모델과 정확한 버전, 벡터 차원
- 문서 중복·삭제·재처리 및 백업 정책
- 성능 측정 기준 (첫 응답 지연, 전체 소요 시간, 메모리 피크)

- 기본설계: 시스템 아키텍처 → 화면·데이터 흐름 → ERD → API 명세 → 패키지 구조

12. 프로젝트 문서 보관 위치

GitHub 저장소 local-knowledge-ai의 docs/01-requirements/requirements.md를 수정 가능한 원본으로 관리하고, 본 PDF는 공유용 산출물로 사용한다. 진행 상태는 docs/PROJECT_STATUS.md, 주요 기술 결정은 docs/adr/에 기록한다.

개정 이력: v1.0 (2026-10-19) - 단일 사용자 / PDF+TXT / 문서 근거만 사용 / Mac 로컬 실행 정책 반영.